DINOSAURによる教師なし物体セグメンテーション（第2報）—スロット数増加実験とバックボーン特徴量のGoldilocks特性—

Unsupervised Object Segmentation via DINOSAUR (Part 2): Slot Number Scaling and the Goldilocks Property of Backbone Features

坂口 健 *1　　中世 大雄 *2
Ken Sakaguchi*1　　Hirooki Nakase

*1電気通信大学　　*2東京大学
The University of Electro-Communications　　The University of Tokyo

第1報では，特徴再構成型の物体中心学習モデルDINOSAURに3種のViTバックボーン（DINOv2, DINOv1, CLIP）を適用し，60サンプルでバックボーン性能序列を検証した．しかし，(1) 材質ラベルの生成にバグがあり正しい評価ができていなかった，(2) スロット数 K=5 がボトルネックとなりバックボーン間の真の性能差を覆い隠していた，という2つの重大な問題が判明した．本第2報では，正しい材質ラベルで再構成したMOVi-A 300サンプルにおいて，K=11 でのスロット数増加実験を実施した．その結果，DINOv2のみがFG-ARIを0.168から0.470へ大幅に改善し，DINOv1（0.176→0.131）とCLIP（0.047→0.110）は改善しないか悪化した．この劇的な差異を特徴量の空間構造，投影後の情報保持，マスク品質，再構成品質の4段階で分析し，DINOv2が「空間的多様性」「情報のコンパクトさ」「特徴スケール」の3軸で適切な中間値を持つ **Goldilocks 特性**を有することを明らかにした．

1. はじめに

物体中心学習（Object-Centric Learning）は，画像や動画をピクセルではなく物体単位で表現する枠組みであり，Slot Attention [Locatello 20] を起点に急速に発展している．DINOSAUR [Seitzer 23] は凍結ViTバックボーンの特徴空間における再構成損失でSlot Attentionを訓練する手法であり，教師なし物体セグメンテーションにおいて高い性能を達成した．

我々は第1報 [Sakaguchi 26a] において，DINOv2, DINOv1, CLIPの3種のViTバックボーンをDINOSAURに適用し，MOVi-A [Greff 22] の金属物体で比較した．しかし，論文投稿後に以下の2つの問題が判明した．

問題1: 材質ラベルのバグ．データ前処理スクリプトにおいて，MOVi-Aの正式な材質ラベル（`instances/material_label`）を取得せず，確率30%でランダムに “metal” ラベルを付与していた．このため第1報の材質別分析（Metal vs Non-metal）は無効であった．

問題2: スロット数 K=5 がボトルネック．MOVi-Aの物体数は3–10個と多様であるが，第1報で設定した K=5 は大半のシーンで物体数に対して不足していた．この制約によりバックボーン間の真の性能差が表面化しなかった可能性がある（DINOv2: 0.168, DINOv1: 0.176）．

本第2報では，これらの問題を修正した上で，スロット数 K=11 への増加実験を実施し，バックボーンの事前学習目的がSlot Attentionのスケーリング挙動に与える影響を分析する．研究の問いを以下に再定義する：

RQ: ViTバックボーンの事前学習目的の違いは，スロット数増加時の物体中心学習の性能にどのような差をもたらすか？

2. 関連研究

Slot Attention [Locatello 20] は，画像特徴を K 個のスロットに競合的に割り当てる注意機構であり，物体中心学習の基盤モジュールである．SAVi [Kipf 22] はこれを時系列に拡張し，DINOSAUR [Seitzer 23] は凍結ViTバックボーンの特徴空間における再構成を導入することで教師なし物体発見の精度を大幅に向上させた．VideoSAUR [Zadaianchuk 23] はDINOSAURを動画に拡張した手法である．

表1: バックボーン仕様．CLIPは768次元を384次元に射影後，共通の64次元MLPに入力する．

	DINOv2	DINOv1	CLIP
モデル	ViT-S/14	ViT-S/16	ViT-B/16
特徴次元	384	384	768→384
パッチサイズ	14	16	16
損失関数	MSE	ch-norm	MSE+det.

バックボーン選択の影響に関して，Lüddecke & Ecker [Lüddecke 25] はDense Attentive Probingにより各ViTの密予測能力を体系的に評価し，DINOv2がDINOv1やCLIPより優位であることを示した．しかし，Slot Attentionにおけるスロット数への依存性は検証されていない．本研究はこのギャップを埋めるものである．

3. 手法

3.1 モデル構成

DINOSAURアーキテクチャに基づくSAVi-DINOSAURモデルを使用する．凍結ViTバックボーンで入力画像（224×224）からパッチ特徴を抽出し，2層MLP（d_{in}→d_{in}→64）で64次元に射影した後，Slot Attention（3イテレーション）で K 個のスロットに分割する．Spatial Broadcast Decoderが各スロットから特徴マップを再構成し，ターゲット特徴との再構成損失で訓練する．

3種のバックボーンの仕様を表1に示す．

3.2 損失関数

DINOv2は標準的なMSE損失を使用する．DINOv1は特徴量のスケールが大きく（ノルム81, DINOv2の1.8倍），標準MSEでは訓練が発散するため，チャンネルごとに正規化してからMSEを計算する**チャンネル正規化損失**（ch-norm）を使用する．CLIPは768次元を384次元に変換する学習可能な射影層を含むため，MSE損失の勾配が再構成ターゲット自体を崩壊させる勾配漏洩が発生する．`.detach()` によりターゲット側の勾配を遮断して対処する．さらに，スロット崩壊を緩和するため，多様化損失（λ_{div}=0.01）を全モデルに追加する．

表 2: 第 1 報からの修正事項.

指摘・反省点	対応
材質ラベルがランダム	正式ラベルで 300 サンプル再構成
Lambert 対照群なし	per-object Material ARI で分析
2 つの RQ が分離	1 つに統合（§ 1 参照）
K=5 がボトルネック	K=11 実験追加
60 サンプルで統計不安定	300 サンプルに拡大
図のフォントが小さい	ポスター用に図を再作成

表 3: K=5 でのバックボーン比較（300 サンプル，正しい材質ラベル）.

モデル	FG-ARI	Metal ARI	Rubber ARI
DINOv2 (MSE)	0.168	0.185	0.218
DINOv1 (ch-norm)	**0.176**	**0.214**	**0.222**
CLIP (MSE+det.)	0.047	0.071	0.068

3.3 実験設定

データ：MOVi-A [Greff 22] の 300 サンプルを使用する．第 1 報の 60 サンプルから 5 倍に拡大し，正しい材質ラベル（TFDS の `instances/material_label`）を per-object で取得した．各サンプルは 128×128 の動画から最初のフレームを取得し，224×224 にリサイズして使用する．

訓練条件：全モデル共通で，バッチサイズ 32，学習率 0.001（warmup 5 エポック＋コサイン減衰），200 エポック訓練する．スロット数は K=5（第 1 報条件）と K=11（本実験）の 2 条件を比較する．K=11 は MOVi-A の最大物体数 10 に背景スロット 1 個を加えた設定である．スロット次元は 64，デコーダ隠れ層は 128 とする．GPU は NVIDIA RTX 5090 を 1 枚使用し，各モデルの訓練は約 5 分で完了する．

評価指標：Foreground Adjusted Rand Index（FG-ARI）を主指標とし，材質別 ARI（Metal ARI, Rubber ARI）で材質の影響を評価する．300 サンプル全体で評価した平均値を報告する．

4. 第 1 報からの修正事項

本第 2 報では，第 1 報に対して以下の修正を行った．第 1 報のレビューア指摘とその対応を表 2 に整理する．

材質ラベルの修正により，第 1 報で報告した材質別差（DINOv2: Metal 0.185 vs Non-metal 0.146, 差+0.039）は正しいラベルでの再評価結果に置き換わる（§ 5.1 参照）.

5. 実験結果

5.1 K=5 でのバックボーン比較（再現実験）

正しい材質ラベル･300 サンプルでの K=5 の結果を表 3 に示す．全体の FG-ARI は DINOv1（0.176）> DINOv2（0.168）> CLIP（0.047）であり，DINOv1 が DINOv2 を⊠差で上回った．これは第 1 報と同傾向であるが，K=5 という制約下ではバックボーン間の差が小さいことを示している．

5.2 K=11 でのスロット数増加実験

表 4 に K=11 の結果を示す．DINOv2 の FG-ARI は 0.168 から **0.470** へ大幅に改善し，第 1 報での最良値の 2.8 倍に達した．一方，DINOv1 は 0.176 から 0.131 に悪化し，CLIP は 0.047 から 0.110 への微改善にとどまった．

K=5 と K=11 の変化をまとめると（表 5），DINOv2 は +0.302 の改善，DINOv1 は −0.045 の悪化，CLIP は +0.063 の微改善であり，スロット数増加に対するスケーリング挙動がバックボーンごとに質的に異なることが確認された．

表 4: K=11 でのバックボーン比較．DINOv2 のみが大幅改善を達成.

モデル	FG-ARI	Metal ARI	Rubber ARI
DINOv2 (MSE)	**0.470**	**0.491**	**0.446**
DINOv1 (ch-norm)	0.131	0.139	0.140
CLIP (MSE+det.)	0.110	0.141	0.144

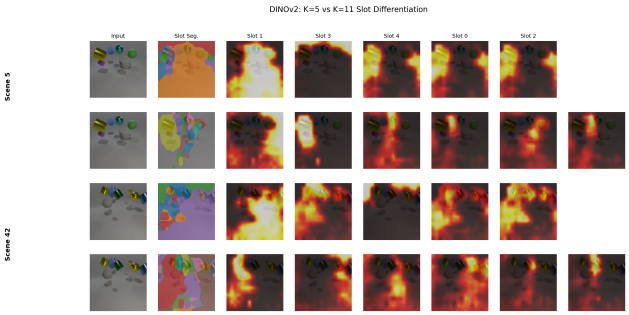

図 1: DINOv2 のスロットマスク比較．各行は左から入力画像，スロットセグメンテーション（argmax），個別スロットの heatmap を示す．K=5 ではマスクが均一で物体分離が不成立だが，K=11 ではスロットが個別の物体・背景に対応する分化を達成している．

図 1 に DINOv2 の K=5 と K=11 におけるスロットマスクを並べて示す．K=5 では全スロットのマスクがほぼ均一で物体境界が不明瞭であるのに対し，K=11 ではスロットが個別の物体や背景領域に対応する分化を示している．

5.3 材質別分析

図 2 に DINOv2 K=11 の複数シーンにおけるスロットマスクを示す．物体数が異なるシーンにおいても，各スロットが個別の物体や背景領域を担当する分化が確認でき，第 1 報で未解決であった「スロットが真に分化しているか」という問いに対して肯定的な結果を得た．

DINOv2 K=11 の per-object Material ARI では，Metal ARI（0.491）が Rubber ARI（0.446）をやや上回ったが，Welch の t 検定で p=0.12 であり統計的に有意な差は確認されなかった．第 1 報で仮説として提示した「鏡面反射が分離を困難にする」効果は，K=11 では顕著には現れなかった．これはスロット数の十分な確保により，鏡面反射によるスロット混同が部分的に緩和されたためと考えられる．

6. 失敗要因分析：なぜ DINOv2 だけが改善するか

同一のアーキテクチャでバックボーンのみが異なるにもかかわらず，K=11 でのスケーリング挙動が劇的に分かれた原因を，特徴量の空間構造から段階的に分析する．

図 3 に同一シーンにおける 3 バックボーンのスロットマスクを並べて示す．DINOv2 は各スロットが物体や背景に明確に対応しているのに対し，DINOv1 は 1 つの支配的スロットが大半を占有（スロット崩壊），CLIP は全スロットがほぼ均一で空間的分離が不成立である．

表 5: K=5 → K=11 における変化量.

モデル	K=5	K=11	Δ
DINOv2	0.168	**0.470**	+0.302
DINOv1	0.176	0.131	−0.045
CLIP	0.047	0.110	+0.063

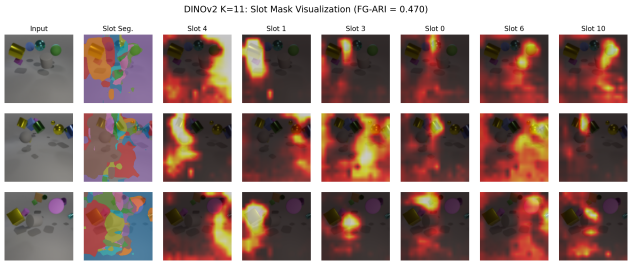

図 2: DINOv2 K=11 のスロットマスク可視化（3 シーン）．各行は左から入力画像，スロットセグメンテーション（argmax 着色），面積上位 6 スロットの heatmap を示す．スロットが個々の物体や背景に対応し，分化が成立している．

6.1 Step 1: バックボーン特徴量の空間構造

各バックボーンが出力する特徴量の空間的多様性を定量化した（表 6）．CLIP は全パッチ間のコサイン類似度が 0.92 とほぼ均一であり，画像全体のカテゴリ情報に特化して空間的位置情報をほとんど持たない．DINOv1 は空間的に最も多様（cos = 0.34）だが，情報が PCA 45 次元に分散している．DINOv2 は cos = 0.52 で中間的な多様性を持ち，PCA 20 次元にコンパクトに情報が集約されている．

6.2 Step 2: 投影層での情報保持

Slot Attention は 64 次元で動作するため，384 次元のバックボーン特徴を 2 層 MLP で圧縮する．この投影前後でのコサイン類似度の変化を表 7 に示す．

DINOv2 と DINOv1 では投影により空間的多様性が増幅される（cos 0.51→0.31，0.34→0.19）．しかし CLIP では 0.93→0.99 とさらに均一化が悪化する．CLIP の投影層は元の特徴量が均一すぎて学習信号が弱く，LayerNorm 重みの標準偏差が 0.002 とほぼ初期値のまま未学習である．

6.3 Step 3: マスク品質

Slot Attention が出力するマスクの品質を直接評価した（表 8）．DINOv2 は全 11 スロットがアクティブに機能し，トップスロットの占有率が 30%と適度に分散した割り当てを実現している．DINOv1 では平均 6.6 スロットのみがアクティブで，トップスロットが 52%を占有する**スロット崩壊**が発生している．CLIP はエントロピーが 0.88 と最大に近く，全マスクがほぼ均一で空間的な位置区別ができていない．

6.4 Step 4: 再構成品質の判定

モデルが空間構造を真に学習しているかを判定するため，全位置に特徴量平均をコピーする自明な戦略（Trivial Mean-Fill）との比率を計算した（表 9）．比率が 1.0 未満であれば空間構造を学習している．

DINOv2 は 0.34 であり，Mean-Fill の 34%まで再構成誤差を削減し，空間構造を忠実に復元している．DINOv1 は 1.09 であり，200 エポック訓練しても Mean-Fill 以上の空間情報を学習できていない．CLIP は 2.16 であり，学習が Mean-Fill より逆効果である．CLIP の Trivial MSE は 0.04 と極小であり，特徴量がほぼ一定のためエポック 4 で自明解に収束する．

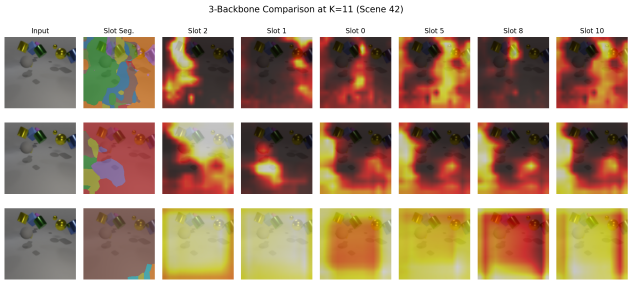

図 3: K=11 における 3 バックボーンのスロットマスク比較（同一シーン）．DINOv2（上段）は物体ごとにスロットが分化．DINOv1（中段）は 1 スロットが支配的でスロット崩壊が発生．CLIP（下段）は全マスクが均一で空間弁別が不成立．

表 6: バックボーン特徴量の空間構造（20 シーン平均）．

指標	DINOv2	DINOv1	CLIP
コサイン類似度	0.52	0.34	0.92
空間分散	2.69	11.88	0.04
PCA 90%次元数	20	45	3
ノルム	46	81	13

7. 考察

7.1 Goldilocks 特性

4 段階の分析結果を総合すると，DINOv2 が Slot Attention にとって 3 つの軸で “ちょうどいい” 特性を持つことが明らかになった（表 10）．“Goldilocks” とは童話「3 匹のくま」に由来する比喩であり，熱すぎず冷たすぎない “ちょうどいい粥” を選ぶ少女の話に基づく．

CLIP の失敗メカニズム：CLIP は CLS トークンによる画像全体のカテゴリ符号化に特化しており，パッチ特徴の空間弁別能力が著しく低い（cos = 0.92）．投影層もほぼ未学習のまま自明解に収束する．

DINOv1 の失敗メカニズム：DINOv1 の特徴量は空間的に豊かだが，PCA 45 次元に情報が分散しているため，384→64 の投影で情報が大幅に失われる．K=5 では必要な情報量が少なく問題が顕在化しなかったが，K=11 では不足する情報でスロットを区別できず，1 スロットが全体の 52%を占有するスロット崩壊が発生する．

DINOv2 の成功要因：DINOv2 は PCA 20 次元に情報が集約されているため 64 次元スロットに十分収まり，かつ適度な空間多様性（cos = 0.52）により投影層が多様性を増幅できる．全 11 スロットが機能分化し，FG-ARI 0.470 を達成する．

7.2 第 1 報の知見の再評価

第 1 報で報告した構造的限界は，K=11 の結果を踏まえて以下のように更新される．

パッチ解像度の壁：16×16 パッチによるマスク境界のにじみは K=11 でも解消されず，ViT アーキテクチャの本質的制約であることが確認された．

鏡面反射によるスロット混同：K=11 では Metal ARI と Rubber ARI の差が統計的に有意でなく（p=0.12），スロット数の確保が鏡面反射の影響を部分的に緩和する可能性が示唆された．

表 7: 投影前後のコサイン類似度と LayerNorm 学習度.

	DINOv2	DINOv1	CLIP
投影前 cos	0.51	0.34	0.93
投影後 cos	0.31	0.19	0.99
変化	↓改善	↓改善	↑**悪化**
LN 重み std	0.034	0.042	0.002

表 8: K=11 でのマスク品質（50 シーン平均）.

指標	DINOv2	DINOv1	CLIP
活性スロット数	11.0	6.6	9.6
トップ占有率	30%	52%	18%
エントロピー/最大	0.60	0.47	0.88
ジニ係数	0.33	0.65	0.36

設計要素の知見：2 層 MLP 射影の必要性，ch-norm 損失，CLIP 勾配漏洩の対処法は K=11 でも同様に有効であった．加えて，DINOv1 では ch-norm 損失で訓練安定性は確保できたものの，投影段階での情報損失によりマスク品質が改善しないという新たな限界が判明した．

7.3 限界と今後の課題

データ規模：MOVi-A 300 サンプルでの実験であり，実世界画像での検証は今後の課題である．Goldilocks 特性がアーキテクチャ起因であればデータセットに依存しない一般性を持つ可能性があるが，実世界画像では特徴量の性質が変わりうる．

DINOv1 の救済：投影層の次元を 64 より大きく設定するか，投影前に PCA で主要次元を選択する前処理が有効である可能性がある．

性能の上限：DINOv2 の FG-ARI 0.470 は DINOSAUR 原論文 [Seitzer 23] の MOVi-C（0.59–0.64）と比較して低い．モデルの大規模化（slot_dim=128, hidden=256）で改善の余地がある．

8. まとめ

本第 2 報では，第 1 報の反省点を修正した上で K=11 のスロット数増加実験を実施し，以下を明らかにした．

(1) スケーリング分岐：DINOv2 の FG-ARI は K=5 の 0.168 から K=11 の 0.470 へ 2.8 倍に改善したが，DINOv1 は悪化（−0.045），CLIP は微改善（+0.063）にとどまった．

(2) Goldilocks 特性：この差異の原因を 4 段階で分析し，DINOv2 が空間的多様性，情報コンパクトさ，特徴スケールの 3 軸で適切な中間値を持つ Goldilocks 特性を有することを特定した．

(3) 工学的教訓：材質ラベルバグとスロット数ボトルネックは，実験設計で最初に確認すべき基本的な要因である．

参考文献

[Locatello 20] Locatello, F., Weissenborn, D., Unterthiner, T., et al.: Object-Centric Learning with Slot Attention, in *Proc. NeurIPS 2020* (2020).

[Kipf 22] Kipf, T., Elsayed, G. F., Mahendran, A., et al.: Conditional Object-Centric Learning from Video, in *Proc. ICLR 2022* (2022).

表 9: 再構成品質の Mean-Fill 基準判定（20 シーン平均）.

	DINOv2	DINOv1	CLIP
再構成 MSE	0.92	12.84	0.08
Mean-Fill MSE	2.69	11.88	0.04
Ratio	**0.34**	1.09	2.16
判定	学習済	未学習	逆効果

表 10: Goldilocks 特性の 3 軸．DINOv2 は全軸で中間値を持つ.

	DINOv2	DINOv1	CLIP
空間多様性 (cos sim)	適度 (0.52)	過剰 (0.34)	不足 (0.92)
情報コンパクト性 (PCA 次元)	適度 (20)	過分散 (45)	過集中 (3)
特徴スケール (ノルム)	適度 (46)	過大 (81)	過小 (13)

[Seitzer 23] Seitzer, M., Horn, M., Zadaianchuk, A., et al.: Bridging the Gap to Real-World Object-Centric Learning, in *Proc. ICLR 2023* (2023).

[Zadaianchuk 23] Zadaianchuk, A., Seitzer, M., Martius, G.: Object-Centric Learning for Real-World Videos by Predicting Temporal Feature Similarities, in *Proc. NeurIPS 2023* (2023).

[Oquab 24] Oquab, M., Darcet, T., Moutakanni, T., et al.: DINOv2: Learning Robust Visual Features without Supervision, *TMLR* (2024).

[Lüddecke 25] Lüddecke, T. and Ecker, A. S.: Characterizing Vision Backbones for Dense Prediction with Dense Attentive Probing, *TMLR* (2025).

[Greff 22] Greff, K., Belletti, F., Beyer, L., et al.: Kubric: A Scalable Dataset Generator, in *Proc. CVPR 2022* (2022).

[Kirillov 23] Kirillov, A., Mintun, E., Ravi, N., et al.: Segment Anything, in *Proc. ICCV 2023* (2023).

[Sakaguchi 26a] 坂口 健, 中世 大雄: DINOSAUR による鏡面反射物体の教師なしセグメンテーション—ViT バックボーンの比較と構造的限界の検証—, 第 40 回人工知能学会全国大会 (2026).