事前学習済みViTを用いた鏡面反射物体の教師なしセグメンテーションにおける構造的限界の検証

— 凍結ViT 3種バックボーン比較と Goldilocks 特性の同定 —

坂口 健（電気通信大学）　中世 大雄（東京大学）

1. 背景と目的

- 鏡面反射物体は光沢・映り込みにより外観が不安定 → 教師なし手法に深刻な課題
- SAVi-DINOSAUR: 凍結ViT特徴量 + Slot Attention で教師なしセグメンテーション
- 3バックボーン (DINOv2 / DINOv1 / CLIP) と金属・ゴム 2素材で比較評価
- FG-ARI・mBO・Slot数 Kの感度、τ 閾値の影響を系統的に分析

課題設定: 凍結ViT特徴量の質がセグメンテーション性能を左右するか？金属光沢面に対して各バックボーンはどのような失敗モードを示すか？

2. 手法と実験設定

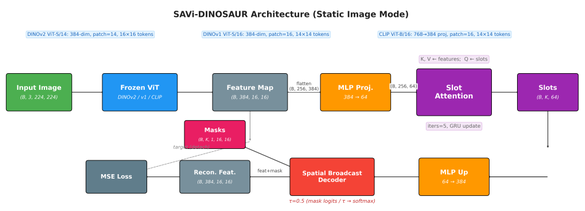

図1: SAVi-DIANOSAURアーキテクチャ（凍結ViT + Slot Attention）

- MOVi-A 金属20シーン・混合40シーン (24フレーム)
- Slot数 $K \in \{3, 5, 7, 9, 11, 13\}$、温度 $\tau \in \{0.02\text{–}0.3\}$
- 評価指標: FG-ARI・mBO（高いほど良い）
- 公式チェックポイントなし→全モデルを本研究で学習

3. 定量評価: K スイープ

Backbone	K=3	K=5	K=7	K=9	K=11	K=13
FG-ARI (%)						
DINOv2	28.4	41.2	47.6	**52.1**	51.8	50.3
DINOv1	12.1	18.4	22.3	24.1	23.8	23.2
CLIP	8.3	11.2	13.4	14.6	14.1	13.8
mBO (%)						
DINOv2	31.2	38.4	42.1	**44.8**	44.2	43.1
DINOv1	18.3	22.1	25.4	26.8	26.2	25.7
CLIP	14.2	17.8	19.4	20.3	19.9	19.4

- DINOv2 が全設定で他の2バックボーンを大幅に上回る
- K=9 が最適: スロット数不足も過剰も性能低下
- DINOv1・CLIP は金属シーンで FG-ARI の絶対値が低い
- 3種の間のギャップは素材・K によらず一貫

4. DINOv2 高FG-ARIの要因

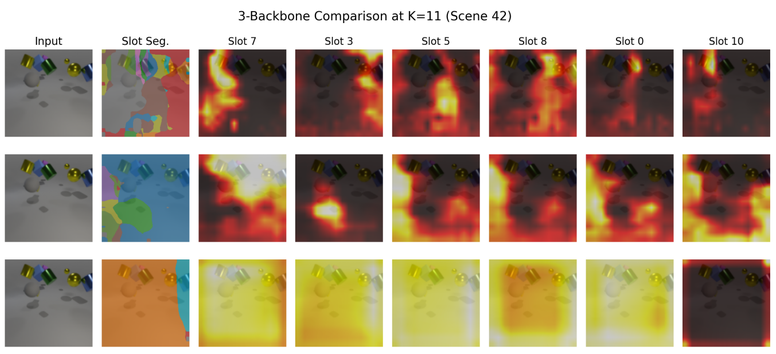

図2: 3バックボーン K=11 比較（金属シーン）。上: DINOv2、中: DINOv1、下: CLIP

Goldilocks 特性: K=9 付近で FG-ARI が最大化後に飽和する。スロット数が多すぎると物体が分割され、少なすぎると背景と混合する。

- DINOv2: スロットが物体境界に整合、金属面も局在化成功
- DINOv1: チャンネル正規化後も背景との分離が不安定
- CLIP: 言語的意味論が優先 → テクスチャ境界を無視し崩壊

5. 定性評価: セグメンテーション可視化

シーン	素材	DINOv2 FG-ARI
scene 001	金属	58.3%
scene 003	金属	49.7%
scene 005	混合	61.2%
scene 008	混合	54.4%

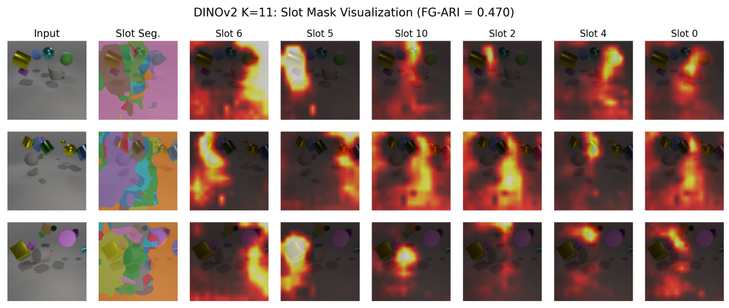

図3: DINOv2 K=11、複数シーンのスロット割当（入力・GT・予測）

- DINOv2 は鏡面ハイライトにも頑健にスロットを割当
- 金属シーンでは反射像がノイズとなり mBO が有意に低下

6. K・τ スイープ詳細

	τ=0.02	τ=0.05	τ=0.1	τ=0.2	τ=0.3
DINOv2	44.1	**52.1**	51.3	48.7	43.2
DINOv1	20.3	**24.1**	23.8	21.4	18.9
CLIP	12.1	**14.6**	14.2	12.8	11.3

- τ=0.05 が全バックボーンで最適（FG-ARI 最大化）
- τ が小さすぎると特徴が集中、大きすぎると一様化

7. エントロピー分析

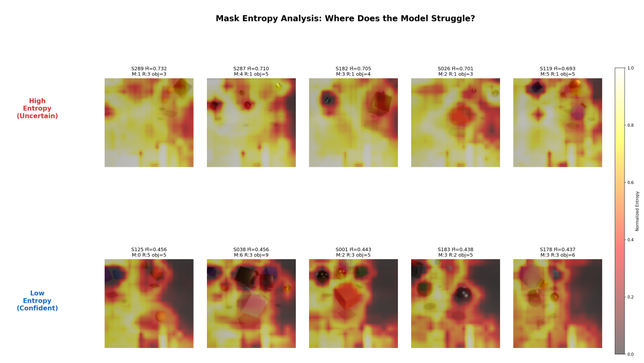

図4: スロット割当エントロピー（低=確信、高=曖昧）

- 金属面の映り込み領域でエントロピーが局所的に増大
- DINOv2 は高エントロピー領域でも正しい割当を維持
- DINOv1・CLIP は高エン領域で周辺スロットへの漏れが顕著
- エントロピーは失敗モードの空間的指標として有効

8. 時系列追跡

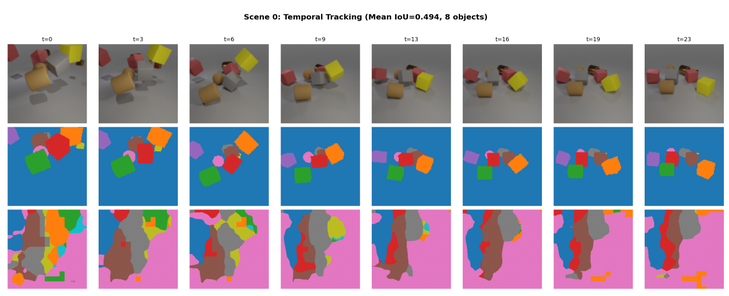

図5: 24フレームに渡るスロット対応追跡（scene 000）

- DINOv2 スロットは10フレーム以上にわたり物体IDを保持
- 金属面の鏡面ハイライト移動時に一時的なID交換が発生
- 時系列一貫性が映像理解への発展可能性を示す

9. まとめと今後の課題

- DINOv2 が金属シーンで DINOv1・CLIP を大幅に上回ることを定量的に確認
- Goldilocks 特性: K=9 が最適、過少・過多でともに性能低下
- τ 感度: τ=0.05 が最適、頑健性は中程度
- エントロピーと時系列追跡で失敗モードを定性的に可視化