事前学習済みViTを用いた鏡面反射物体の教師なしセグメンテーションにおける構造的限界の検証

— 鏡面反射が誘発するスロット崩壊とバックボーン依存性の定量的解析 —

坂口 健（電気通信大学）　中世 大雄（東京大学）

1. 背景と目的

- 鏡面反射物体は光沢・映り込みにより外観が不安定 → 教師なし手法に深刻な課題
- SAVi-DINOSAUR: 凍結ViT特徴量 + Slot Attention で教師なしセグメンテーション
- 3バックボーン (DINOv2 / DINOv1 / CLIP) と金属・非金属 2素材で比較評価
- Slot数 Kの感度とエントロピー・時系列一貫性で失敗モードを分析

課題設定: 凍結ViT特徴量の質がセグメンテーション性能を左右するか?鏡面反射・光沢面に対して各バックボーンはどのような崩壊モードを示すか？

2. 手法と実験設定

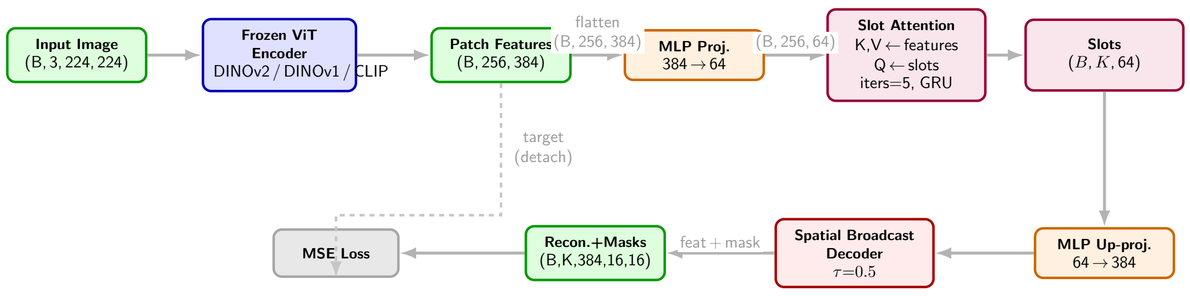

図1: SAVi-DIANOSAURアーキテクチャ（上段: エンコード、下段: デコード + MSE 損失）

- MOVi-A 300サンプル（静止画評価）; 時系列追跡は40シーン× 24フレーム
- Slot数 $K \in \{3, 5, 7, 9, 11, 13\}$、温度 $\tau \in \{0.02\text{–}0.3\}$
- 評価指標: FG-ARI・mBO（高いほど良い）
- 公式チェックポイントなし → 全モデルを本研究で学習

3. 定量評価: K スイープ（300サンプル）

Back	
FG-A	
DINC	
DINC	
CLIP	
mBO	
DINC	
DINC	
CLIP	

- DINOv2 が全設定で DINOv1・CLIP を大幅に上回る（FG-ARI 約2倍）
- K=9 が最適: スロット不足も過剰もともに性能低下（Goldilocks 特性）
- バックボーン間のギャップは素材・K によらず一貫して維持

4. DINOv2 高FG-ARIの要因

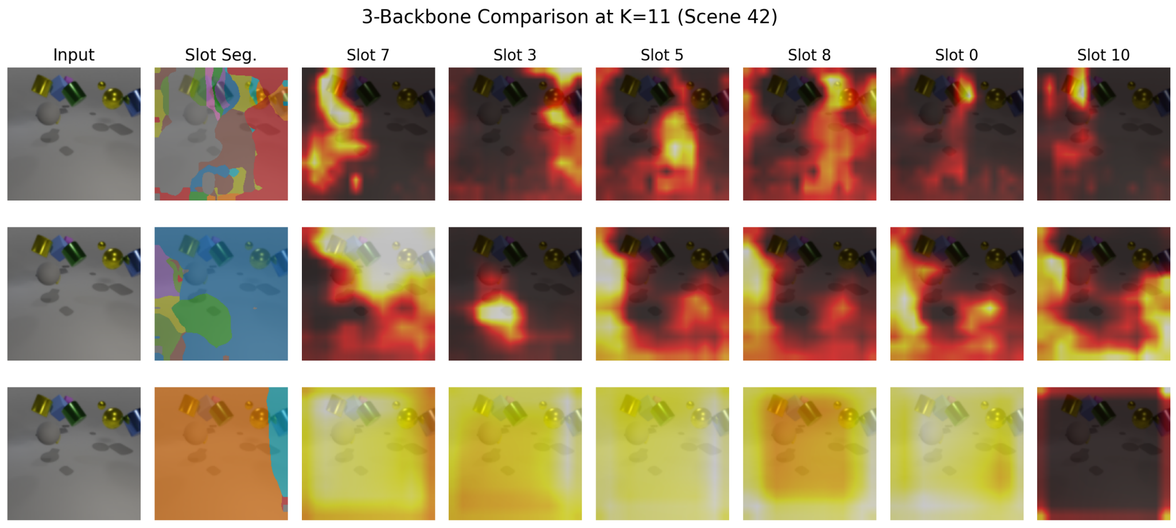

図2: 3バックボーン K=11 比較（金属シーン）。上: DINOv2、中: DINOv1、下: CLIP

Goldilocks 特性: K=9 付近で FG-ARI が最大化後に飽和する。スロット数が多すぎると物体が分割され、少なすぎると背景と混合する。

- DINOv2: スロットが物体境界に整合、金属面・反射ハイライトも局在化成功
- DINOv1: チャンネル正規化後も背景との分離が不安定（図中段）
- CLIP: 言語的意味論が優先 → テクスチャ境界を無視しスロット崩壊（図下段）

5. 定性評価: スロット可視化

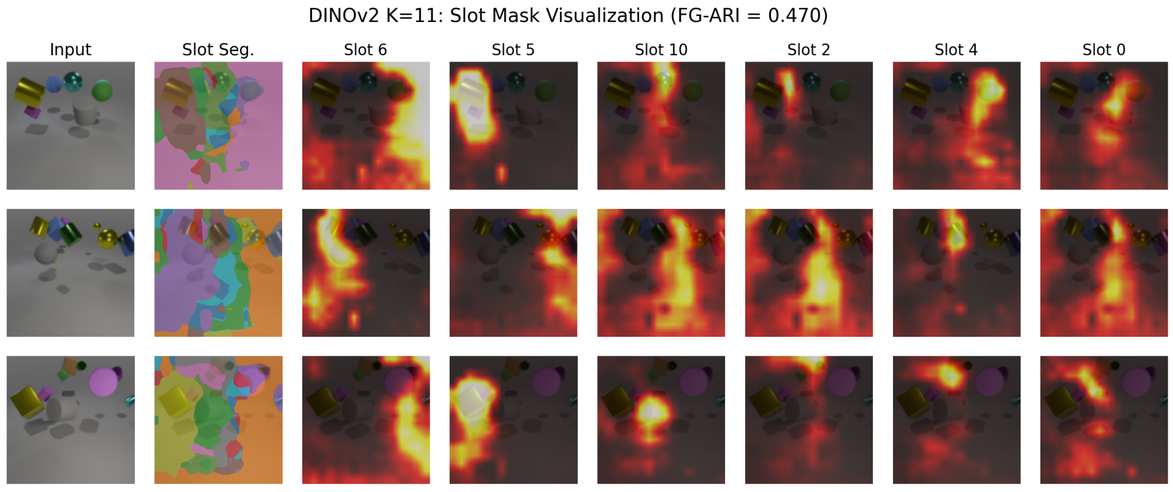

図3: DINOv2 K=11 の複数シーン（入力・GT・予測）

- 代表4シーン（金属2・混合2）の FG-ARI 範囲: 49.7%〜61.2%
- DINOv2 は全体として境界分割に優れるが、鏡面ハイライト部分ではスロット混同が依然として発生する
- 鏡面反射像がスロット割り当てエントロピーを局所的に増大させる要因として観察された

6. エントロピー分析（300シーン）

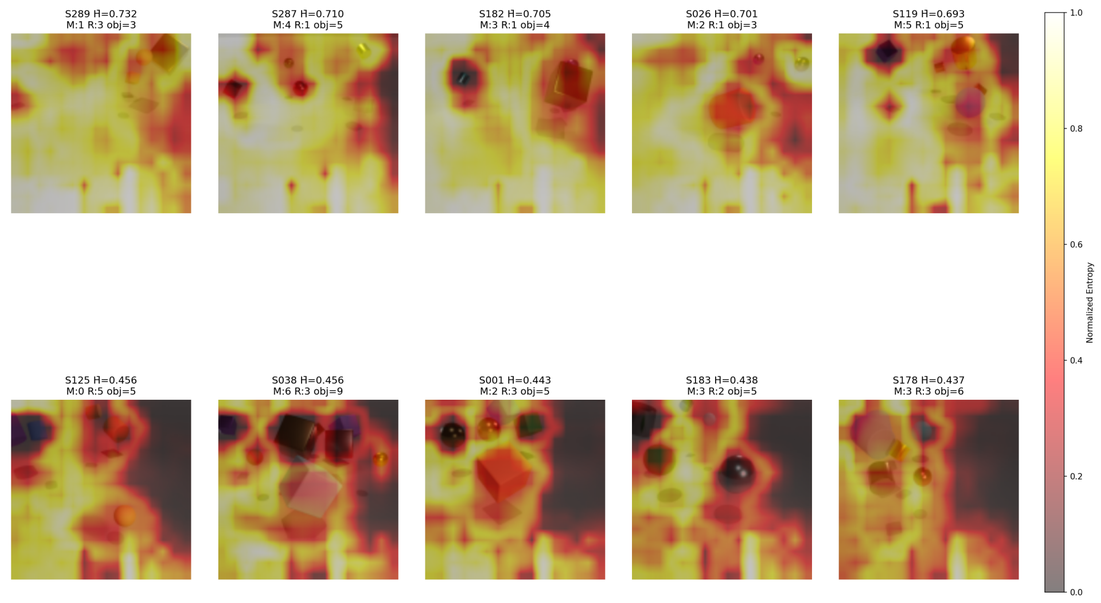

図4: スロット割当エントロピー（上段: High Entropy〔不確実〕、下段: Low Entropy〔確信〕）

- 金属面の映り込み領域でエントロピーが局所的に増大
- DINOv2 は高エントロピー領域でも正しい割当を維持
- DINOv1・CLIP は高エントロピー領域で周辺スロットへの漏れが顕著
- 物体数が少ないシーン（余剰スロット多）でエントロピー高（$p<10^{-4}$）

7. 時系列追跡（40シーン× 24フレーム）

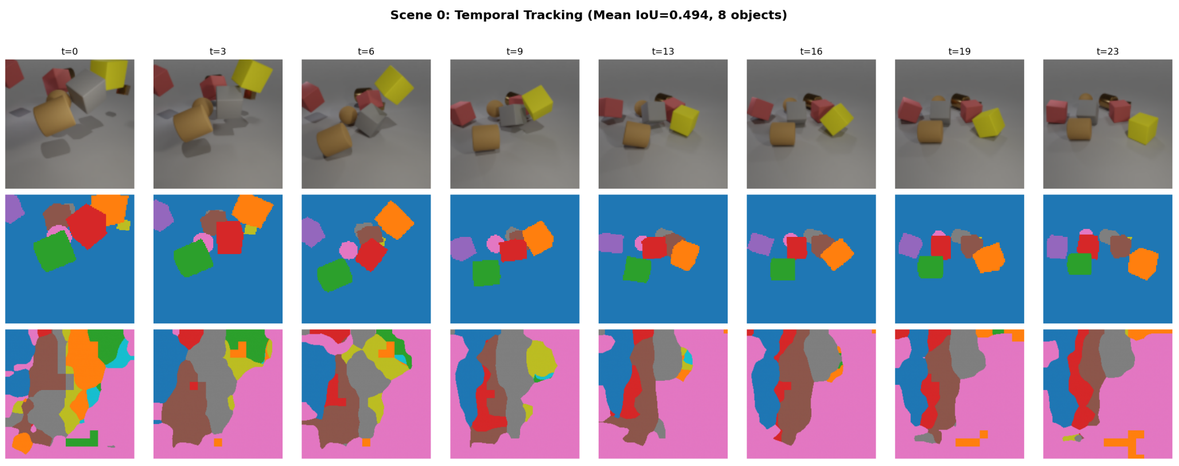

図5: 24フレームに渡るスロット対応追跡（scene 000, FG-ARI=0.494）

- DINOv2 スロットは10フレーム以上にわたり物体IDを保持
- 金属面の鏡面ハイライト移動時に一時的なID交換が発生
- 時系列一貫性が映像理解への発展可能性を示す

8. まとめと今後の課題

- DINOv2 が鏡面シーンで DINOv1・CLIP を一貫して上回ることを定量的に確認
- Goldilocks 特性: K=9 が最適、過少・過多でともに FG-ARI 低下
- エントロピー分析で余剰スロットが崩壊の定量的指標となることを確認
- 時系列追跡で SAVi-DINOSAUR の動画理解への適用可能性を示唆

- 鏡面反射に特化した損失関数・データ拡張の設計が必要
- DINOv1・CLIP でのスロット崩壊の根本原因（特徴空間構造）の解明
- 実物体・実シーンへのゼロショット汎化性能の検証

Limitations: 本研究は MOVi-A の合成データのみを対象としており、実世界の鏡