

DINOSAURによる鏡面反射物体の教師なしセグメンテーション

— ViT バックボーンの比較と構造的限界の検証 —

坂口 健（電気通信大学） 中世 大雄（東京大学）

1. 背景と目的

- モデル : DINOSAUR (凍結 ViT + Slot Attention)
- 目的 : 鏡面反射物体への適用可能性の検証
- 課題 : バックボーン選択の影響の解明
- データ : MOVi-A (金属 20 + 混合 40 = 60 件)

2. 3 種のバックボーン比較と定量結果

モデル	損失種別	FG-ARI (\uparrow)	Metal FG-ARI
DINOv2 ViT-S/14	MSE	0.165	0.185
DINOv1 ViT-S/16	ch-norm	0.153	0.154
CLIP ViT-B/16	MSE+detach	0.041	0.048

⇒ DINOv2 が最高精度 (FG-ARI 0.165)
⇒ CLIP は空間弁別能力の不足により 0.041

⇒ DINOv1 はスケール差で破綻 → ch-norm 損失で解決 (0.153)

3. 構造的限界の可視化（定性分析）★本研究の中心的貢献




図 1: DINOv2 スロットマスク — 16×16 パッチによる境界のにじみ

限界 1

14px パッチ起因の
16×16 解像度の壁
→ CRF・SAM 等が必要




図 2: 3 種バックボーン比較 (MOVi-A 金属物体) — 金属面でのスロット混同

限界 2

BRDF Specular 成分が
スロット混同を誘発
→ 視点依存デコーディング必要

4. まとめと今後の課題

(1) DINOv2 のバックボーンとしての優位性を確認

(2) 16×16 解像度の限界 → SAM 等の高解像度モデルとの統合が必要

(3) 鏡面反射への対応 → 3 次元反射モデルの導入が必要