事前学習目的の異なる ViT 特徴量が物体中心学習に与える影響

— DINOSAUR ＋ 3 種バックボーン（DINOv2/DINOv1/CLIP）の比較と失敗要因分析 —

坂口 健（電気通信大学）　中世 大雄（東京大学）

1. 背景と研究課題

モデル：DINOSAUR（凍結 ViT ＋ Slot Attention）
RQ：事前学習目的が異なる *ViT* 特徴量は物体中心学習でどう振る舞うか？

データ：MOVi-A 300 シーン（24 フレーム，128×128→224×224）
評価：FG-ARI（前景物体の分離精度，↑）
構成：凍結 ViT ＋ 2 層 MLP(384→64) ＋ Slot Attention ＋ Spatial Broadcast Decoder

バックボーン	事前学習	特徴次元
DINOv2 ViT-S/14	自己蒸留 v2	384
DINOv1 ViT-S/16	自己蒸留 v1	384
CLIP ViT-B/16	画像-テキスト	768→384

3. 失敗要因分析：なぜ DINOv2 だけが K=11 で成功するのか ★ 中心的貢献

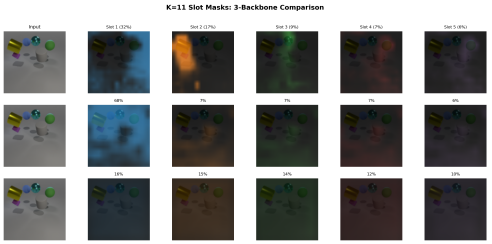

図 1: K=11 スロットマスク比較 — DINOv2 は物体ごとに分離，DINOv1 は 1 スロット支配（52%），CLIP は均一

2. 定量結果：スロット数 K の効果 ★

バックボーン	損失	K=5（物体数以下） FG-ARI	K=5 Metal ARI	K=11（物体数以上） FG-ARI	K=11 Metal ARI	Δ
DINOv2 ViT-S/14	MSE	0.168	0.185	**0.470**	0.491	+0.302
DINOv1 ViT-S/16	ch-norm	0.176	0.214	0.131	0.139	−0.045
CLIP ViT-B/16	MSE+dtch	0.047	0.071	0.110	0.141	+0.063

⇒ K=5: DINOv2≈DINOv1≫CLIP　⇒ K=11: **DINOv2 のみ大幅改善**（0.168→**0.470**），DINOv1 は悪化，CLIP は微改善
⇒ 材質：Metal ARI > Rubber（DINOv2 K=11 で 0.491 vs 0.446，p=0.12 — 統計的に有意ではないが方向は一致）

“Goldilocks 特性”：DINOv2 が “ちょうどいい” 理由

	CLIP (均一すぎ)	**DINOv2** (適度)	DINOv1 (複雑すぎ)
cos 類似度	0.92	**0.52**	0.34
PCA 次元	3	**20**	45
活動スロット	9.6	**11.0**	6.6
再構成/Mean 比	2.16×	**0.34**✓	1.09△

CLIP 失敗：空間均一 → 投影で悪化 (cos 0.92→0.99)→ 全マスク均一 →ep4 で自明解
DINOv1 失敗：45 次元必要 →384→64 投影で喪失 →1 スロット支配 → 再構成 ≈ 平均充填
DINOv2 成功：20 次元にコンパクト → 投影後も多様性維持 → 全 11 スロット活動 →FG-ARI 0.470

4. 時系列追跡の予備実験（今後の課題）

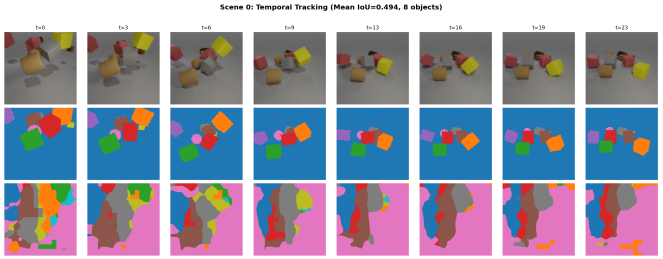

図 **2**: 最良シーン（IoU=0.494）の時系列セグメンテーション推移 — 前半フレームで追跡が維持されるが後半でスロット入替りが発生

静止画訓練→動画追跡の検証

指標	値
平均 IoU 一貫性	0.413 ± 0.035
最良シーン	0.494
最悪シーン	0.356
ランダム基準	≈ 0.09

課題: 静止画訓練のみでは時間的一貫性 IoU≈0.41 に限界
展望: VideoSAUR 型の動画損失導入でスロット追跡性能の大幅改善が期待

5. まとめと工学的教訓

(1) DINOv2 は “Goldilocks 特性” により Slot Attention と最適な相性 → K=11 で FG-ARI **0.470**

(2) スロット数はバックボーン特性に強く依存（DINOv2 のみ K=11 が有効）

(3) 工学的知見：2 層 MLP 射影，ch-norm 損失（DINOv1），勾配 detach（CLIP），温度 τ=0.5

(4) 最適 K はデータセット固有（物体数分布に依存）

(5) 静止画訓練のみでは時系列追跡に限界（IoU≈0.41）→ 動画学習が今後の課題