事前学習目的の異なる ViT 特徴量が物体中心学習に与える影響

— DINOSAUR ＋ 3 種バックボーン（DINOv2/DINOv1/CLIP）の比較と失敗要因分析 —

坂口 健（電気通信大学）　中世 大雄（東京大学）

1. 背景と研究課題

モデル：DINOSAUR（凍結 ViT ＋ Slot Attention）
RQ：事前学習目的が異なる *ViT* 特徴量は物体中心学習でどう振る舞うか？

データ：MOVi-A 300 シーン（24 フレーム，128×128→224×224）
評価：FG-ARI（前景物体の分離精度，↑）
構成：凍結 ViT ＋ 2 層 MLP(384→64) ＋ Slot Attention ＋ Spatial Broadcast Decoder

バックボーン	事前学習	特徴次元
DINOv2 ViT-S/14	自己蒸留 v2	384
DINOv1 ViT-S/16	自己蒸留 v1	384
CLIP ViT-B/16	画像-テキスト	768→384

2. 定量結果：スロット数 K の効果 ★

		K=5（物体数以下）		K=11（物体数以上）		
バックボーン	損失	FG-ARI	Metal ARI	FG-ARI	Metal ARI	Δ
DINOv2 ViT-S/14	MSE	0.168	0.185	**0.470**	0.491	+0.302
DINOv1 ViT-S/16	ch-norm	0.176	0.214	0.131	0.139	−0.045
CLIP ViT-B/16	MSE+dtch	0.047	0.071	0.110	0.141	+0.063

⇒ K=5: DINOv2≈DINOv1≫CLIP　⇒ K=11: **DINOv2 のみ大幅改善**（0.168→**0.470**），DINOv1 は悪化，CLIP は微改善
⇒ 材質：Metal ARI > Rubber（DINOv2 K=11 で 0.491 vs 0.446，p=0.12 — 統計的に有意ではないが方向は一致）

3. 失敗要因分析：なぜ DINOv2 だけが K=11 で成功するのか ★ 中心的貢献

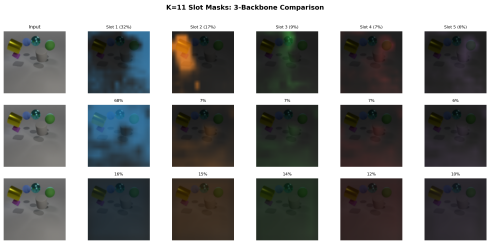

図 1: K=11 スロットマスク比較 — DINOv2 は物体ごとに分離，DINOv1 は 1 スロット支配（52%），CLIP は均一

“Goldilocks 特性”：DINOv2 が “ちょうどいい” 理由

	CLIP (均一すぎ)	**DINOv2** (適度)	DINOv1 (複雑すぎ)
cos 類似度	0.92	**0.52**	0.34
PCA 次元	3	**20**	45
活動スロット	9.6	**11.0**	6.6
再構成/Mean 比	2.16×	**0.34**✓	1.09△

CLIP 失敗：空間均一 → 投影で悪化（cos 0.92→0.99）→ 全マスク均一 →ep4 で自明解
DINOv1 失敗：45 次元必要 →384→64 投影で喪失 →1 スロット支配 → 再構成 ≈ 平均充填
DINOv2 成功：20 次元にコンパクト → 投影後も多様性維持 → 全 11 スロット活動 →FG-ARI 0.470

4. まとめと工学的教訓

(1) DINOv2 は “Goldilocks 特性” により Slot Attention と最適な相性 → K=11 で FG-ARI **0.470**

(2) スロット数はバックボーン特性に強く依存（DINOv2 のみ K=11 が有効）

(3) 工学的知見：2 層 MLP 射影，ch-norm 損失（DINOv1），勾配 detach（CLIP），温度 τ=0.5

(4) 16×16 パッチ解像度の壁 → SAM 等との統合が今後の課題